

Olá!

Este teste avalia sua expertise em dbt + Prefect + BigQuery para nosso Data Lakehouse. Não há a necessidade de executar na GCP, podes executar localmente com DuckDB. Mas se quiseres fazer em um ambiente cloud, fique à vontade.

Considere os seguintes dados:

Dados	Link Direto	Tamanho	Formato
ESTABELECIMENTOS	Download dados-abertos-rf-cnpj.casadosdados.com	1.2GB	ZIP→CSV
EMPRESAS	Download dados-abertos-rf-cnpj.casadosdados.com	300MB	ZIP→CSV
SOCIOS	Download dados-abertos-rf-cnpj.casadosdados.com	400MB	ZIP→CSV
Simples Nacional	Download dados-abertos-rf-cnpj.casadosdados.com	50MB	ZIP→CSV
CNAE	Download CSV gov	2MB	CSV
ReceitaWS API	https://receitaws.com.br/v1/cnpj/{CNPJ}	-	JSON

Mirror oficial: dados.gov.br/cnpj

Exercício:

1. dbt Core Funcional

Estruture um projeto dbt seguindo as melhores práticas de modelagem (ex: arquitetura em camadas).

Requisitos:

- Materializações adequadas (configure o uso de incremental onde fizer sentido prático para simular um ambiente de produção).
- Crie modelos de staging para padronização básica dos dados brutos.

- Crie uma tabela fato consolidando métricas de empresas ativas e tabelas dimensão relevantes (ex: hierarquia de CNAEs).]
- Implemente um Snapshot (SCD Type 2) para rastrear o histórico de alterações de um campo crítico (ex: Capital Social).

2. Macros Jinja

Demonstre sua capacidade de criar código SQL modular e dinâmico.

Requisitos:

- Desenvolva e aplique no mínimo 3 macros que resolvam problemas reais de negócio ou engenharia (ex: formatação/parse de campos complexos, padronização, auditoria).

3. Testes dbt

Garanta a confiabilidade do seu pipeline de dados.

Requisitos:

- Implemente no mínimo 8 testes, que devem abranger obrigatoriamente:
- Testes genéricos nativos (unicidade, não-nulos, integridade referencial entre tabelas, valores aceitos).
- Pelo menos um teste customizado via pacote externo (ex: dbt_utils) ou macro própria que valide uma regra de negócio específica (ex: quantidade de sócios maior que zero).

4. Prefect Flow

Crie um fluxo automatizado que integre extração e transformação. Desenvolva um Flow contendo Tasks que:

- Faça a extração e carga de uma amostra dos dados (recomendamos ~10.000 linhas por arquivo para otimizar o tempo de execução local).
- Orquestre a execução do pipeline de transformação (dbt run) e a validação de qualidade (dbt test).

5. FinOps e Otimização para BigQuery

Gere uma documentação com uma proposta de projeto do modelo desenvolvido, mas dentro de um ambiente cloud.

Requisitos:

- Descreva a estratégia de otimização de custos e performance caso esse pipeline rodasse no BigQuery real.
- Defina e justifique suas escolhas de Partitioning e Clustering. Estime (conceitualmente) como essas escolhas impactariam na redução de slots lidos e nos custos de query.

- Estructure o documento de forma clara pensando no onboarding de novos colaboradores. O documento deve ter entre 4 e 7 páginas.
- Inclua no documento o link do projeto desenvolvido, ou então, envie em anexo os artefatos construídos. Caso o link seja privado, envie os dados para acesso no email de resposta.

 Critérios de Avaliação (100pts)

Critério	Pts	Checklist
dbt Mastery	30	Macros, incremental, snapshots, 8+ testes
Arquitetura	25	Prefect→dbt→BigQuery, resilience
Data Quality	20	Testes + tratamento nulos/duplicatas
BigQuery FinOps	15	Partitioning, clustering, custo
Código/Execução	10	Funciona local, Git limpo